探 索 性 实 验

报 告

课程名称：	《数据挖掘》
实验名称	景区游览指南的程序性知识挖掘
组号	第___组
组长姓名/学号	组长姓名/学号
组员姓名/学号	组员 1 姓名/学号 组员 2 姓名/学号
学生专业：	软件工程
授课教师：	蔡毅 / 许可 （写自己班的老师）
开课学期：	2026-2027-01

华南理工大学软件学院

2026 年 10 月

地　　点：	B7 后座 楼　　133/231/233
实验日期与时间：	第 9 周周三 9-12 节 第 11 周周三 9-12 节
总评分	分/100 分
实验项目 1 得分	分/100 分
实验项目 2 得分	分/100 分
实验项目 3 得分	分/100 分
实验项目 4 得分	分/100 分
实验项目 5 得分	分/100 分
实验项目 6 得分	分/100 分
实验项目 7 得分	分/100 分
实验总结反思得分	分/100 分
探索性实验总体批改意见：	
批改人	蔡毅、许可

*请不要修改此页

小组信息和组内评分

组号：第　　组

姓名	角色	主要工作和贡献	组内评分
	组长		%
	组员		%
	组员		%

*说明：1、请提交报告时，组长组织组员一起填写好本页，组内评分请根据实际情况，进行合理分配；2、组内人数为N人，组内评分总和为N*100%

共同要求

允许使用等价工具或技术路线。允许 LLM 辅助，但须解释关键逻辑、规则或 Prompt 及验证方法。截图用于证明运行，不能替代源代码、结构化结果和关键中间产物；报告中的结果应能与代码、文件逐一对应。

章节	核心工作 / 报告重点	评分
第 1 章	3 个景区的数据准备、清洗、结构化与质量检查	基础 100 分；附加后封顶 100 分
第 2 章	三类实体定义、识别、位置记录与可视化迭代	100 分
第 3 章	路线解析、时间层级、名称归一化；路线对比为附加题	基础 100 分；附加后封顶 100 分
第 4 章	代词检测、人工标注、消解与效果评估	100 分
第 5 章	条件—建议抽取、分类去重与统计图	100 分
第 6 章	多源融合、图谱模式、构建、展示与质量验证	100 分
第 7 章	LLM 接入、图谱工具、Agent 闭环与多场景测试	100 分
第 8 章	至少 2 个失败现象；局限性与 1 个突破点的研究方案	100 分

《数据挖掘》探索性实验报告
—实验项目 1 景区指南数据采集与预处理

1.1 实验目标与数据准备

本实验围绕景区游览指南的程序性知识挖掘，完成多源文本的数据准备、清洗、结构化保存和质量检查。清洗结果保留景点、交通方式、时间表达及游览顺序，为后续实体识别、路线层级解析、共指消解和条件建议抽取提供统一输入。

数据采用公开语料与官网补充材料的混合方式，不编写或运行网页爬虫。游客游记来自用户指定的 ModelScope 数据集 BAAI/IndustryCorpus2，读取 tourism_geography/chinese 下 high/rank_00130.parquet 与 middle/rank_00712.parquet 两个分片，分别含 21,401 条和 187,404 条记录，共 208,805 条。实验只使用这两个分片，未扫描整个数据集。分片路径、文件大小、SHA-256 及记录数量见 data/source/manifest.json。

原语料实际包含 text、_id、industry_type、quality_score 及若干质量统计字段。其中 text 为正文，_id 为原记录标识，industry_type 为行业标签，quality_score 为数据集已有质量分，不是本实验评价分。先按景区及攻略、路线、游记等词筛出候选，再对正文中的本人或同行者游览经历、具体景点和行程信息进行 LLM 辅助逐条内容复核，最终目的抽样选择黄山、九寨沟、张家界各 5 篇游记。文章开头偶然提及景区、主体为其他地区或纯百科新闻的材料不计入。该抽样用于教学实验，不代表整体语料分布，也未核验原作者身份。

原语料不含原网页 URL，不能仅凭正文口吻判定为官方。因此另从黄山旅游官方平台、九寨沟景区官方网站及湖南省文化和旅游厅公开页面补充路线材料，各景区整理为 1 份官方路线指南，共 3 份；同一指南可能含多条备选路线，不将其拆成多篇游记。黄山和九寨沟保留原 HTML 快照，张家界因直接下载连接失败，采用已阅读核验官方页面的人工摘录，保留 URL、标题及摘录范围。

表 1-1 最终数据组成

景区	官方指南份数	游客游记篇数	合计
黄山	1	5	6
九寨沟	1	5	6
张家界	1	5	6
总计	3	15	18

官方补充来源：[1] 黄山旅游官方平台《黄山风景区清明假期常见旅游咨询》第 20 问，https://wap.huangshan.com.cn/detail/strategy/fjqlyzx；[2] 九寨沟景区《游玩方式》的一日精华游部分，https://www.jiuzhai.com/intelligent-service/way-of-play；[3] 湖南省文化和旅游厅《直达武陵源 乐享张家界——武陵源自驾游精品线路推荐》中的景区自驾一日游部分，https://whhlyt.hunan.gov.cn/whhlyt/wldhlylx/202208/t20220816_27584140.html。访问与整理日期为 2026 年 10 月 28 日。

1.2 清洗方法与实现流程

处理流程为：加载 Parquet 分片并按固定记录定位 → 整理 18 份原始材料为 JSONL → 批量清洗 → 检查字段、空值及重复 → 导出 CSV 与 JSONL → 生成审计记录与质量报告。prepare_data.py 负责原记录定位及官方节选整理；run_lab1.py 负责离线清洗与检查。selected_raw.jsonl 保留选中材料的原始内容，不覆盖原文。

HTML 处理：仅在检测到实际标签时使用 BeautifulSoup 解析，删除 script、style 与 noscript 节点，把段落、换行和本次官网使用的 font 块映射为换行，再提取正文。黄山官网正文存放于页面脚本的 JSON 字段内，先解析该字段，再取第 20 问对应的原 HTML 段落；不能直接删除页面脚本，否则会丢失整段指南。

噪声处理：删除语料中的“图片发自简书 app”占位文字；识别责任编辑、本篇游记统计、平台免责声明等明确尾部标记，截断后面的网页推荐与互动内容；删除明确来源、原标题及地址与电话元数据行。原始来源字段保留在结构化记录中，正文网址清理不影响来源追溯。未命中明确规则的文字不推测性删除。

格式统一：统一 CRLF/CR 为 LF，解码 HTML 实体，清除零宽和控制字符，将全角 ASCII 字符转换为半角，压缩行内重复空白，去除行首尾空白和空行。保留中文逗号与英文逗号的混用，不进行全局标点替换；保留箭头、长横线、序号、数字、时间和计量单位。未做分词、停用词删除或自动纠错，避免损伤后续路线与实体信息。

异常处理：清洗正文为空、景区或类型不在允许值内的记录进入拒绝清单；对清洗正文计算 SHA-256 进行完全去重并保留首条。相同景区、相同文本类型的记录两两计算 SequenceMatcher 字符序列相似度，阈值为 0.80，仅用于近重复复核提示，不自动删除相似路线。对替换字符 U+FFFD 及可疑改写词另行检查，不猜测修复原意。本次 18 条输入均保留。

本项目独立环境为 D:\miniconda3\envs\dm_scenic_lab，实际 Python 版本为 3.11.18。运行时使用该环境的 python.exe，不使用 base 或其他项目环境。核心依赖为 pyarrow 26.0.0、beautifulsoup4 4.15.0；锁定版本见 requirements.txt。

离线复现：在项目根目录运行 & D:\miniconda3\envs\dm_scenic_lab\python.exe .\src\run_lab1.py 。输入为 data/raw/selected_raw.jsonl，输出目录为 outputs。若需从原 Parquet 重建选中材料，先运行 src/prepare_data.py，再运行清洗入口。完整命令和下载说明见 README.md。

1.3 结构化数据设计

数据以一份完整的选中游记或一份官方指南节选为一条记录。CSV 使用 UTF-8 BOM 与标准引号转义，正文内换行保留；JSONL 使用 UTF-8，每行一个 JSON 对象，便于后续批处理。两份输出包含同一批 18 条记录和一致的正文。

表 1-2 实际输出字段设计

字段	类型	含义
doc_id	字符串	HS/JZG/ZJJ 景区前缀；0 为官方指南，T 为游记；项目内唯一

字段	类型	含义
scenic / text_type	字符串	景区；官方路线或游客游记
source_name / source_url	字符串	数据集或官方发布平台名称及入口 URL
original_url	字符串	原网页 URL；15 篇语料游记为空，官方材料填官网 URL
source_file / source_record_id	字符串	原分片或快照/摘录文件；语料_id 或官方节选标识
source_row_index	整数或 null	Parquet 分片内从 0 开始的行号；官方材料为 null
title / acquired_date	字符串	游记为首行截取摘要，非核验原标题；官方为页面/节选标题；整理日期
original_text / clean_text	字符串	选中原文（官网可为原 HTML 节选）与清洗后正文
quality_score	数值或 null	原语料已有质量分；官方补充未评分
provenance_status / classification_basis / scope_note	字符串	来源核验状态、类型判断依据及范围/历史性说明
original_chars / clean_chars / content_sha256	整数/字符串	清洗前后 Python 字符长度；清洗文本 SHA-256

“官方路线”依据发布机构和官网域名核验；“游客游记”依据文章内容中的游览经历判定，并在 provenance_status 中明确原发布者和网页未核验。source_url 为数据集入口不等于原文链接，original_url 缺失保持为空，绝不补造。原语料的 64 位_id 按字符串保存，避免 Excel 打开时出现科学计数法或精度丢失；在 Excel 导入 CSV 时应将该列指定为文本。

后续实验可用 doc_id 关联数据，以 clean_text 作为识别文本。实体字符位置须基于这一版清洗文本记录；若继续修改清洗规则，应重新生成实体位置，不能混用原文和清洗文本的偏移。

1.4 清洗前后对比与数据质量

本次输入 18 条、输出 18 条，无删除记录；其中 12 条正文发生变化，6 条未命中需修改的规则并原样保留。清洗前原始字段共 77,960 个字符，清洗后共 73,324 个字符，减少 4,636 个字符。原始字段中含 HTML，因此该变化只能说明标签及噪声减少，不能直接解释为正文信息损失率。

表 1-3 自动质量检查结果

检查项	结果	检查方式
景区及类型覆盖	3 个景区，各 1 份官方指南+5 篇游记	按 scenic 和 text_type 分组计数
核心字段缺失	0	检查 7 个必填字段是否为空白
游记原网页 URL 缺失	15/15	单独统计 original_url,不与数据集入口混淆
文档 ID 重复 / 完全重复正文	0 / 0	ID 集合检查 / 清洗正文 SHA-256
近重复候选	0 对	同景区同类型；字符序列相似度≥0.80
残留 HTML / U+FFFD	0 / 0	标签模式检查 / 替换字符计数
空白格式违规 / 清洗幂等失败	0 / 0	检查 CR、连续空白；再次清洗结果应不变
CSV 读回一致性	18 条正文均一致	CSV 读回后逐条对比 JSONL 正文

例 1，HS-T01，语料_id=150600027865，清洗前 1618 字符、清洗后 1518 字符。原文片段：“只有一天的时间,所以就趁着还早去了趟老街. 图片发自简书 app 徽式老建筑,青石板路,橘黄街灯,古色古香.胡兴堂的黄山烧饼早早已经卖断货,一路樟木和烧饼香,人头攒动,却自有一”；清洗后对应片段：“只有一天的时间,所以就趁着还早去了趟老街. 徽式老建筑,青石板路,橘黄街灯,古色古香.胡兴堂的黄山烧饼早早已经卖断货,一路樟木和烧饼香,人头攒动,却自有一”。删除图片占位文字，保留“因为提前买了一日团”等行程正文。

例 2，JZG-001，原 HTML 片段为 沟口乘车→原始森林（7:00-8:10 一个小时车程）；清洗后为“沟口乘车→原始森林(7:00-8:10 一个小时车程)”。HTML 标签和重复空白被去除，全角括号统一，箭头、景点、起止时间和车程文字保留。程序还验证了 13:30-14:20 这一时间段未丢失。

例 3，HS-T04，原文 2062 字符，清洗后 1745 字符。原网页尾部从“[责任编辑:紫荆蓝]”开始，后续含与旅游无关的推荐标题，按明确尾部标记整体截去；截断之前的黄山游览正文保留。例 4，ZJJ-T05 删除单独的客栈地址与电话元数据行，原始行仍可在 original_text 中复核。

实际命中规则包括：2 条材料去除 HTML，10 次图片占位文字删除，4 次网页尾部截断，1 条元数据行删除，3 条材料发生全角 ASCII 归一化。未命中的网址删除、控制字符与明显乱码规则仍保留在代码中，但不把它们写成本批数据已经出现的问题。

详细证据见 outputs/cleaning_audit.csv、before_after_samples.json、scenic_counts.csv 和 quality_report.json。检查结果由 run_lab1.py 实际计算，数量以文件为准，不以截图替代数据。

1.5 问题与分析

问题一：行业标签与景区名只能筛出候选，不能保证主题正确。筛选中发现一篇文章开头提到以后想去张家界，正文实际是德天瀑布、通灵峡谷和涠洲岛自驾游。若仅按关键词命中就收录，会造成景区错配。处理时依据正文主题、实际到访与行程景点复核，排除该记录（原_id=499700012157），不将其计入最终 18 条。

问题二：语料缺少原网页来源，官方身份无法验证。采用混合来源补齐官方材料，语料记录保留分片名、原_id、从 0 计的分片行号及文件哈希；15 篇游记的原 URL 仍为空。张家界官方页面可检索阅读，但直接保存 HTML 连接失败，因此保留人工摘录文本并明确其证据形态，不声称已下载完整网页。

问题三：原文包含历史性、主观性和潜在错误信息。例如 HS-T05 涉及 2009 年行程及翻越封闭位置的叙述，HS-T04 含投喂猴子的经历，JZG-T02 含逃票叙述；这些属于待研究文本，不是本实验赞成的建议。清洗阶段不把原文事实擅自改写，审计中标记可疑行为；后续条件建议抽取与 Agent 应用应过滤不当行为，并重新核验票价、开放状态等时效信息。

问题四：官方文本也可能有时间冲突。JZG-001 最后一段写“17:00-17:35”，前一段结束时间为 17:20，存在重叠；本实验保留原文，不把推测改正写入数据。路线层级实验应标注冲突，不能将所有时间直接当作可靠调度约束。张家界官网页面发布时间为 2022-08-16，文末署名日期为 2021-09-18，两者不混为一谈。

问题五：跨景区行程与来源迁移说明仍需下游判断。张家界游记含黄龙洞、天门山及凤凰古城等行程；九寨沟游记也可能包含重庆、成都等沿途地点。为保留上下文，本实验按整篇保留并在 scope_note 注明范围，后续实体和路线抽取必须区分核心景区、外围景点和交通城市，不能把整篇所有地点都归为同一景区内部节点。

最终输出可供后续实验直接按 doc_id、scenic、text_type 读取 clean_text。18 条记录满足每景区至少 1 份官方路线和 5 篇游客游记的数据数量安排；本实验完成的是基础数据工程，不宣称已完成实体识别、路线解析或建议抽取。内容筛选及报告整理使用 LLM 辅助，关键清洗逻辑、实际输入输出和程序检查均可复现；本次未以小样本结果估计整体语料准确率。

《数据挖掘》探索性实验报告
—实验项目 2 游览步骤的实体识别

2.1 输入数据与实体定义规范

（引用项目 1 清洗数据，列出使用的景区与文本范围。定义景点 POI、交通方式、时间节点三类实体，明确边界、纳入 / 排除规则与歧义处理，并说明如何在多个景区保持一致。）

2.2 识别方法与批量实现

（说明采用词典、规则、LLM 或等价方法的理由和流程。给出核心词典、规则或 Prompt 及参数，说明景区专属词和常见表达的覆盖；交代多景区批量处理、失败重试 / 异常处理及结果稳定性。）

2.3 实体输出与出现位置

（输出结构化实体文件，至少保留实体文本、实体类型、来源和出现位置。可采用文档 ID ＋字符起止位置；须声明位置对应哪版文本、起点是否从 0 计及结束位置是否包含。多次出现的实体应能分别定位。）

2.4 人工抽查与错误分析

（说明抽查范围、选择方式和判定依据，检查误识别、漏识别、歧义、重复及类型混乱。列出代表性原句、预测、人工判断和改进办法；无需将人工抽查写成未经计算的准确率。）

2.5 三类实体词频可视化与迭代

（统计三类实体词频并绘制词云或柱状图，说明计数口径、文本范围及是否归一化。根据图中噪声调整停用词、领域词典或规则；展示调整内容、重新运行结果和优化前后变化。）

《数据挖掘》探索性实验报告
—实验项目 3 游览路线的层级结构挖掘

3.1 路线描述模式与输入范围

（选取 1—2 个景区的官方路线文本，归纳箭头链路、编号列表、按时间分段等实际出现的格式。展示原文片段并说明解析难点；实现对至少 1—2 种典型格式的解析，明确实际支持范围。）

3.2 统一结构化表示与解析程序

（设计至少包含步骤、时间、景点、活动的表示，说明字段类型、顺序及缺失处理。给出核心解析规则 / 流程和代码位置，输出 JSON / CSV 等结构化路线；不得把缺失时间当作原文事实。）

3.3 时间层级构建

（在解析结果上构建上午 / 中午 / 下午或等价层级，说明时间段划分依据，组织景点、活动和先后关系。未明确时间的步骤说明归属或待定策略；给出层级数据或清晰结构图。）

3.4 名称归一化与稳健性

（说明简称 / 全称、俗称 / 正式名、子景点 / 父区域、周边景点和重复实体的处理；用样例解释哪些可以合并、哪些应保留，避免过度对齐，并交代规则局限。）

3.5 结构结果验证

（核查路线步骤是否遗漏或重复、顺序是否保持、景点与活动是否对应、时间层级是否合理。提供原文→解析结果→层级结构的可追溯例证，并分析失败样例。）

3.6 官方与游客实际路线对比【附加题】

（选取同一景区的官方路线与游记实际路线，转换为可比较表示；至少从两个维度进行量化或结构对比，例如景点覆盖、顺序一致性、时间分配、停留时长或路线相似度。说明指标计算、缺失处理和可比性，并结合原文分析差异原因。未选做请注明。）

《数据挖掘》探索性实验报告
—实验项目 4 程序性知识的共指消解

4.1 代词检测与待消解样本

（从 3—5 篇游记构建样本，说明检测“它、这、那里、他们”等表达的范围和分句方法。保存来源、句子、代词及位置；同句出现多个相同代词时应能区分，不能仅以“代词字符串”作为唯一键。）

4.2 人工标注真实先行词

（对待消解样本建立人工标注，给出不少于 5 个可核验案例，以便完成步骤要求的 5 例人工评估。明确标注字段、先行词边界、类型及无明确先行词 / 不确定的处理规则；标注应基于原文上下文。）

4.3 消解方法与实现

（实现至少一种规则、现有模型、简单分类或 LLM 推理方法。交代候选先行词生成、选择逻辑、上下文窗口、参数 / Prompt 及无法判断时的策略。说明 POI 优先、距离或类型约束如何与旅游文本匹配。）

4.4 消解结果与输出

（输出代词—预测先行词对应关系，以及消解后的文本或知识三元组；保留与原文的映射，展示消解前后变化。）

4.5 人工核验与评价

（使用人工标注核验至少 5 个案例。说明准确率、覆盖率等所用指标的分子、分母和无明确先行词样本的计入方式，报告真实计数；样本较少时说明结论局限。）

《数据挖掘》探索性实验报告
—实验项目 5 条件性游览建议的抽取

5.1 输入与抽取规则设计

（说明使用哪些游记和官方指南；覆盖“如果 / 假如 / 若 / 建议 / 可以”等典型表达，采用规则、语义方法或 LLM 均可。定义如何切分条件部分与建议部分，交代规则优先级和适用边界，避免把所有“建议 / 可以”直接当作完整条件句。）

5.2 批量抽取与复杂表达处理

（描述批量处理流程，保留景区、来源文本和原句。说明多建议句、跨分句表达如何处理；条件不明确时说明保留、排除或人工补充依据，不能将推断伪装成原文条件。）

5.3 映射表、分类与去重

（输出条件类型、条件描述、建议内容、来源景区 / 文本等核心字段；按游客类型或条件类型分类。说明同句重复、近重复、前后缀重复的处理，避免同一建议严重碎片化；合并时保留来源线索。）

5.4 人工校验与误差分析

（说明抽查范围及判定标准，检查误抽、漏抽、条件 / 建议边界及分类错误；展示人工修正依据。记录去重前后数量和合并例子，说明是否因样本稀疏导致某些类别缺失，避免编造建议补齐统计。）

5.5 分类统计与可视化

（按任务步骤，对映射表按游客类型分组统计并绘制对比柱状图；说明统计单位、类别划分及空类别处理，结合图表解释主要现象。）

《数据挖掘》探索性实验报告
—实验项目 6 多源程序性知识的融合与图谱可视化

6.1 输入关联与融合策略

（读取并关联项目 2 实体和项目 3 路线，说明官方与游客来源知识如何进入融合流程；项目 5 条件建议可选融入。列出输入文件和关联键，说明对齐、去重、频次 / 置信度或来源合并策略；保留必要属性及来源。）

6.2 对齐样例与噪声诊断

（展示相同实体的对齐与不应合并的反例；解释低频、异常或噪声候选的过滤依据与影响。频次低不等于必然错误，应说明本组实际规则及其局限。）

6.3 图谱模式（Schema）设计

（定义节点类型、标识及属性，定义关系类型、方向、两端节点及属性。可使用景点、操作、时间等节点及先后、包含、条件等关系；以本组实际任务为准，解释各关系的语义。）

6.4 构建实现与结构化输出

（用 NetworkX、Neo4j 或等价方式实际构建图。说明节点 / 边生成、导入或构图入口，保存可读取的结构文件或数据库，报告节点、边及类型数量，并检查关联是否正确。节点数量不是质量的替代指标。）

6.5 图谱可视化

（至少展示一个景区较完整的知识网络；图中应能辨识节点类型、边类型或关键关系。说明布局、过滤策略，突出关键节点和路径；局部细节图可另附，不宜只提交零散截图。）

6.6 质量验证与结果分析

（用查询、统计或人工检查验证节点 / 边及基本连通关系；给出查询输入、实际返回与判断依据。分析核心节点、典型路径、缺失或错误关系，能够追溯到原文或上游输出。）

《数据挖掘》探索性实验报告
—实验项目 7 程序性知识应用：旅游规划Agent

7.1 架构与 LLM 接入

（设计意图 / 约束解析、图谱查询、路线规划和回答生成等模块，给出数据流及基本输入输出。说明所用 LLM、API 或本地部署方式、主要配置和 Prompt；展示如何解析景区、游客类型、时长等约束。）

7.2 图谱查询工具封装

（将项目 6 图谱封装为 Agent 可调用的实际查询工具；仅把图谱内容写入 Prompt 不等于工具封装。定义工具名称、输入输出 Schema、参数、返回结构及无结果 / 异常格式，展示一次真实调用。）

7.3 闭环编排与回退策略

（实现 ReAct 或等价的“解析 / 决策→调用工具→读取结果→生成回答”闭环。说明如何决定是否及怎样调用工具、查询结果如何参与最终方案，以及无匹配、缺少信息、约束冲突或执行失败时的回退 / 追问策略。）

7.4 多场景功能与鲁棒性测试

（至少测试 3 类不同约束场景，可改变游客类型、时长、景区等。测试还应覆盖无匹配、信息不足和冲突约束的处理，可复用前三类或增补测试。每例列出用户输入、预期检查点、实际调用 / 返回、最终输出和判断，不能只附聊天截图。）

7.5 一次完整执行与失败分析

（展示至少一条便于核查的完整记录：输入→解析约束→工具名与参数→实际返回→最终方案，并标出方案中哪些景点、路径或建议来自返回结果。可提供工具日志或结构化中间状态；分析不合理输出及原因。）

7.6 交互入口与配置

（提供命令行或 Web 可用入口；列出依赖、模型配置、环境变量名、启动命令和测试步骤。共享报告与代码仅填写密钥变量名及配置方法，实际凭据不写入模板。）

7.7 旅游规划 Agent 示范用例

（选取一条典型用户请求，完整演示 Agent 从约束解析、ReAct 决策、知识图谱工具调用到行程生成的全链路，用于直观展示系统工作流程，注意所有截图需要有图题）

《数据挖掘》探索性实验报告
—实验总结：探索性实验总结反思

一、回顾并记录实验过程中出现的至少 2 个失败现象，并深入分析可能导致这些问题的原因；尝试提出针对性的改进思路或优化方案

1、失败现象记录

2、失败原因深度分析

3、改进/优化方案

二、你们的整体技术方案目前存在哪些局限性？如果给你一个学期的时间继续深入研究，你最希望突破其中的哪个技术点？尝试提出突破该技术点的思路或方案？

1、梳理现有技术方案的局限性

2、选定一个优先突破的技术点，并给出说明

3、突破该技术点的研究思路或实施方案

附录

一、提交前自查

☐ 封面及小组贡献页已填写，组内评分合计为 N×100%。
☐ 7 个实验及总结反思内容完整；未实现 / 未选做部分如实说明。
☐ 报告、代码、结构化输出、图表和日志相互对应。
☐ 总结含至少 2 个失败现象、至少 2 条具体局限及仅 1 个研究突破点。
☐ 排版规范、语句通顺、图表清晰（图有图题，表有表题，图按顺序标号、图按顺序标号）。

二、提交时间与方式（按任务书）

截止：2026 年 11 月 20 日 24:00 前。由各小组组长提交

文档命名方式：第 X 组_组长姓名_《数据挖掘》探索性实验报告

蔡毅老师班：1099235614@qq.com
许可老师班：2118151758@qq.com