探 索 性 实 验

报 告

课程名称：	《数据挖掘》
实验名称	景区游览指南的程序性知识挖掘
组号	第___组
组长姓名/学号	组长姓名/学号
组员姓名/学号	组员 1 姓名/学号 组员 2 姓名/学号
学生专业：	软件工程
授课教师：	蔡毅 / 许可 （写自己班的老师）
开课学期：	2026-2027-01

华南理工大学软件学院

2026 年 10 月

地　　点：	B7 后座 楼　　133/231/233
实验日期与时间：	第 9 周周三 9-12 节 第 11 周周三 9-12 节
总评分	分/100 分
实验项目 1 得分	分/100 分
实验项目 2 得分	分/100 分
实验项目 3 得分	分/100 分
实验项目 4 得分	分/100 分
实验项目 5 得分	分/100 分
实验项目 6 得分	分/100 分
实验项目 7 得分	分/100 分
实验总结反思得分	分/100 分
探索性实验总体批改意见：	
批改人	蔡毅、许可

*请不要修改此页

小组信息和组内评分

组号：第　　组

姓名	角色	主要工作和贡献	组内评分
	组长		%
	组员		%
	组员		%

*说明：1、请提交报告时，组长组织组员一起填写好本页，组内评分请根据实际情况，进行合理分配；2、组内人数为N人，组内评分总和为N*100%

共同要求

允许使用等价工具或技术路线。允许 LLM 辅助，但须解释关键逻辑、规则或 Prompt 及验证方法。截图用于证明运行，不能替代源代码、结构化结果和关键中间产物；报告中的结果应能与代码、文件逐一对应。

章节	核心工作 / 报告重点	评分
第 1 章	3 个景区的数据准备、清洗、结构化与质量检查	基础 100 分；附加后封顶 100 分
第 2 章	三类实体定义、识别、位置记录与可视化迭代	100 分
第 3 章	路线解析、时间层级、名称归一化；路线对比为附加题	基础 100 分；附加后封顶 100 分
第 4 章	代词检测、人工标注、消解与效果评估	100 分
第 5 章	条件—建议抽取、分类去重与统计图	100 分
第 6 章	多源融合、图谱模式、构建、展示与质量验证	100 分
第 7 章	LLM 接入、图谱工具、Agent 闭环与多场景测试	100 分
第 8 章	至少 2 个失败现象；局限性与 1 个突破点的研究方案	100 分

《数据挖掘》探索性实验报告
—实验项目 1 景区指南数据采集与预处理

1.1 实验目标与数据准备

（说明数据将如何支撑后续实体、路线及条件建议抽取。准备 3 个景区的官方路线与游客游记；注明自采、教师提供或混合。自采须交代工具、采集步骤或脚本；使用教师数据须说明加载方法、字段含义和来源。）

1.2 清洗方法与实现流程

（说明批量读入→噪声处理→格式统一→异常检查→保存的流程；解释 HTML 标签、网址 / 元数据、异常符号、空白 / 换行 / 标点 / 编码、乱码与冗余内容的处理。说明空值、重复、异常字段是删除、修复还是保留，避免误删路线顺序或时间信息。）

1.3 结构化数据设计

（列出实际字段、类型和含义。核心信息应覆盖来源、景区、文本类型、原始内容；为后续复核建议保留文档 ID、清洗文本。说明如何区分官方路线与游客游记，以及输出格式（Excel / CSV / JSON 等）。）

1.4 清洗前后对比与数据质量

（提供可核验的原文—清洗后样例，标明文档 ID 和具体变化；覆盖主要规则。统计清洗前后记录数、各景区及文本类型数量、缺失值、重复与格式一致性。未发现问题也应说明检查方法及结果。）

1.5 问题与分析

（记录采集或清洗中遇到的实际问题、处理方式和遗留影响，说明哪些清洗结果可供后续实验直接读取。）

《数据挖掘》探索性实验报告
—实验项目 2 游览步骤的实体识别

2.1 输入数据与实体定义规范

（引用项目 1 清洗数据，列出使用的景区与文本范围。定义景点 POI、交通方式、时间节点三类实体，明确边界、纳入 / 排除规则与歧义处理，并说明如何在多个景区保持一致。）

2.2 识别方法与批量实现

（说明采用词典、规则、LLM 或等价方法的理由和流程。给出核心词典、规则或 Prompt 及参数，说明景区专属词和常见表达的覆盖；交代多景区批量处理、失败重试 / 异常处理及结果稳定性。）

2.3 实体输出与出现位置

（输出结构化实体文件，至少保留实体文本、实体类型、来源和出现位置。可采用文档 ID ＋字符起止位置；须声明位置对应哪版文本、起点是否从 0 计及结束位置是否包含。多次出现的实体应能分别定位。）

2.4 人工抽查与错误分析

（说明抽查范围、选择方式和判定依据，检查误识别、漏识别、歧义、重复及类型混乱。列出代表性原句、预测、人工判断和改进办法；无需将人工抽查写成未经计算的准确率。）

2.5 三类实体词频可视化与迭代

（统计三类实体词频并绘制词云或柱状图，说明计数口径、文本范围及是否归一化。根据图中噪声调整停用词、领域词典或规则；展示调整内容、重新运行结果和优化前后变化。）

《数据挖掘》探索性实验报告
—实验项目 3 游览路线的层级结构挖掘

3.1 路线描述模式与输入范围

（选取 1—2 个景区的官方路线文本，归纳箭头链路、编号列表、按时间分段等实际出现的格式。展示原文片段并说明解析难点；实现对至少 1—2 种典型格式的解析，明确实际支持范围。）

3.2 统一结构化表示与解析程序

（设计至少包含步骤、时间、景点、活动的表示，说明字段类型、顺序及缺失处理。给出核心解析规则 / 流程和代码位置，输出 JSON / CSV 等结构化路线；不得把缺失时间当作原文事实。）

3.3 时间层级构建

（在解析结果上构建上午 / 中午 / 下午或等价层级，说明时间段划分依据，组织景点、活动和先后关系。未明确时间的步骤说明归属或待定策略；给出层级数据或清晰结构图。）

3.4 名称归一化与稳健性

（说明简称 / 全称、俗称 / 正式名、子景点 / 父区域、周边景点和重复实体的处理；用样例解释哪些可以合并、哪些应保留，避免过度对齐，并交代规则局限。）

3.5 结构结果验证

（核查路线步骤是否遗漏或重复、顺序是否保持、景点与活动是否对应、时间层级是否合理。提供原文→解析结果→层级结构的可追溯例证，并分析失败样例。）

3.6 官方与游客实际路线对比【附加题】

（选取同一景区的官方路线与游记实际路线，转换为可比较表示；至少从两个维度进行量化或结构对比，例如景点覆盖、顺序一致性、时间分配、停留时长或路线相似度。说明指标计算、缺失处理和可比性，并结合原文分析差异原因。未选做请注明。）

《数据挖掘》探索性实验报告
—实验项目 4 程序性知识的共指消解

4.1 代词检测与待消解样本

（从 3—5 篇游记构建样本，说明检测“它、这、那里、他们”等表达的范围和分句方法。保存来源、句子、代词及位置；同句出现多个相同代词时应能区分，不能仅以“代词字符串”作为唯一键。）

4.2 人工标注真实先行词

（对待消解样本建立人工标注，给出不少于 5 个可核验案例，以便完成步骤要求的 5 例人工评估。明确标注字段、先行词边界、类型及无明确先行词 / 不确定的处理规则；标注应基于原文上下文。）

4.3 消解方法与实现

（实现至少一种规则、现有模型、简单分类或 LLM 推理方法。交代候选先行词生成、选择逻辑、上下文窗口、参数 / Prompt 及无法判断时的策略。说明 POI 优先、距离或类型约束如何与旅游文本匹配。）

4.4 消解结果与输出

（输出代词—预测先行词对应关系，以及消解后的文本或知识三元组；保留与原文的映射，展示消解前后变化。）

4.5 人工核验与评价

（使用人工标注核验至少 5 个案例。说明准确率、覆盖率等所用指标的分子、分母和无明确先行词样本的计入方式，报告真实计数；样本较少时说明结论局限。）

《数据挖掘》探索性实验报告
—实验项目 5 条件性游览建议的抽取

5.1 输入与抽取规则设计

（说明使用哪些游记和官方指南；覆盖“如果 / 假如 / 若 / 建议 / 可以”等典型表达，采用规则、语义方法或 LLM 均可。定义如何切分条件部分与建议部分，交代规则优先级和适用边界，避免把所有“建议 / 可以”直接当作完整条件句。）

5.2 批量抽取与复杂表达处理

（描述批量处理流程，保留景区、来源文本和原句。说明多建议句、跨分句表达如何处理；条件不明确时说明保留、排除或人工补充依据，不能将推断伪装成原文条件。）

5.3 映射表、分类与去重

（输出条件类型、条件描述、建议内容、来源景区 / 文本等核心字段；按游客类型或条件类型分类。说明同句重复、近重复、前后缀重复的处理，避免同一建议严重碎片化；合并时保留来源线索。）

5.4 人工校验与误差分析

（说明抽查范围及判定标准，检查误抽、漏抽、条件 / 建议边界及分类错误；展示人工修正依据。记录去重前后数量和合并例子，说明是否因样本稀疏导致某些类别缺失，避免编造建议补齐统计。）

5.5 分类统计与可视化

（按任务步骤，对映射表按游客类型分组统计并绘制对比柱状图；说明统计单位、类别划分及空类别处理，结合图表解释主要现象。）

《数据挖掘》探索性实验报告
—实验项目 6 多源程序性知识的融合与图谱可视化

6.1 输入关联与融合策略

（读取并关联项目 2 实体和项目 3 路线，说明官方与游客来源知识如何进入融合流程；项目 5 条件建议可选融入。列出输入文件和关联键，说明对齐、去重、频次 / 置信度或来源合并策略；保留必要属性及来源。）

6.2 对齐样例与噪声诊断

（展示相同实体的对齐与不应合并的反例；解释低频、异常或噪声候选的过滤依据与影响。频次低不等于必然错误，应说明本组实际规则及其局限。）

6.3 图谱模式（Schema）设计

（定义节点类型、标识及属性，定义关系类型、方向、两端节点及属性。可使用景点、操作、时间等节点及先后、包含、条件等关系；以本组实际任务为准，解释各关系的语义。）

6.4 构建实现与结构化输出

（用 NetworkX、Neo4j 或等价方式实际构建图。说明节点 / 边生成、导入或构图入口，保存可读取的结构文件或数据库，报告节点、边及类型数量，并检查关联是否正确。节点数量不是质量的替代指标。）

6.5 图谱可视化

（至少展示一个景区较完整的知识网络；图中应能辨识节点类型、边类型或关键关系。说明布局、过滤策略，突出关键节点和路径；局部细节图可另附，不宜只提交零散截图。）

6.6 质量验证与结果分析

（用查询、统计或人工检查验证节点 / 边及基本连通关系；给出查询输入、实际返回与判断依据。分析核心节点、典型路径、缺失或错误关系，能够追溯到原文或上游输出。）

《数据挖掘》探索性实验报告
—实验项目 7 程序性知识应用：旅游规划Agent

7.1 架构与 LLM 接入

（设计意图 / 约束解析、图谱查询、路线规划和回答生成等模块，给出数据流及基本输入输出。说明所用 LLM、API 或本地部署方式、主要配置和 Prompt；展示如何解析景区、游客类型、时长等约束。）

7.2 图谱查询工具封装

（将项目 6 图谱封装为 Agent 可调用的实际查询工具；仅把图谱内容写入 Prompt 不等于工具封装。定义工具名称、输入输出 Schema、参数、返回结构及无结果 / 异常格式，展示一次真实调用。）

7.3 闭环编排与回退策略

（实现 ReAct 或等价的“解析 / 决策→调用工具→读取结果→生成回答”闭环。说明如何决定是否及怎样调用工具、查询结果如何参与最终方案，以及无匹配、缺少信息、约束冲突或执行失败时的回退 / 追问策略。）

7.4 多场景功能与鲁棒性测试

（至少测试 3 类不同约束场景，可改变游客类型、时长、景区等。测试还应覆盖无匹配、信息不足和冲突约束的处理，可复用前三类或增补测试。每例列出用户输入、预期检查点、实际调用 / 返回、最终输出和判断，不能只附聊天截图。）

7.5 一次完整执行与失败分析

（展示至少一条便于核查的完整记录：输入→解析约束→工具名与参数→实际返回→最终方案，并标出方案中哪些景点、路径或建议来自返回结果。可提供工具日志或结构化中间状态；分析不合理输出及原因。）

7.6 交互入口与配置

（提供命令行或 Web 可用入口；列出依赖、模型配置、环境变量名、启动命令和测试步骤。共享报告与代码仅填写密钥变量名及配置方法，实际凭据不写入模板。）

7.7 旅游规划 Agent 示范用例

（选取一条典型用户请求，完整演示 Agent 从约束解析、ReAct 决策、知识图谱工具调用到行程生成的全链路，用于直观展示系统工作流程，注意所有截图需要有图题）

《数据挖掘》探索性实验报告
—实验总结：探索性实验总结反思

一、回顾并记录实验过程中出现的至少 2 个失败现象，并深入分析可能导致这些问题的原因；尝试提出针对性的改进思路或优化方案

1、失败现象记录

2、失败原因深度分析

3、改进/优化方案

二、你们的整体技术方案目前存在哪些局限性？如果给你一个学期的时间继续深入研究，你最希望突破其中的哪个技术点？尝试提出突破该技术点的思路或方案？

1、梳理现有技术方案的局限性

2、选定一个优先突破的技术点，并给出说明

3、突破该技术点的研究思路或实施方案

附录

一、提交前自查

☐ 封面及小组贡献页已填写，组内评分合计为 N×100%。
☐ 7 个实验及总结反思内容完整；未实现 / 未选做部分如实说明。
☐ 报告、代码、结构化输出、图表和日志相互对应。
☐ 总结含至少 2 个失败现象、至少 2 条具体局限及仅 1 个研究突破点。
☐ 排版规范、语句通顺、图表清晰（图有图题，表有表题，图按顺序标号、图按顺序标号）。

二、提交时间与方式（按任务书）

截止：2026 年 11 月 20 日 24:00 前。由各小组组长提交

文档命名方式：第 X 组_组长姓名_《数据挖掘》探索性实验报告

蔡毅老师班：1099235614@qq.com
许可老师班：2118151758@qq.com